

RELAZIONE

Questa analisi statistica si propone di applicare il modello di regressione lineare semplice per la comprensione delle motivazioni dietro le differenze interregionali nelle quantità di “prestiti per società non finanziarie e famiglie produttrici”, disponendo tali quantità per regione in un primo momento, e tentando di spiegare le differenze interregionale con la variabile “grado di istruzione”.

Il risultato è stato un’associazione debole, infatti il grado d’istruzione sembrerebbe non essere la causa vera dietro queste differenze nell’ammontare dei prestiti richiesti e concessi per le famiglie produttrici.

In un primo momento il sottoscritto pensava (erroneamente) di poter spiegare l’evidente disparità interregionale con il grado d’istruzione; un pensiero nato evidentemente da un pregiudizio del sottoscritto: pensavo che nelle regioni del nord, ed in particolare la Lombardia, questo maggiore accesso ai prestiti potesse essere dovuto proprio ad un maggiore grado d’istruzione rispetto alle regioni del sud.

È comune pensare al sud come “zona con meno accesso all’istruzione e quindi meno propensione a richiedere prestiti”? non so quanto sia comune, ma sono in parte calabrese e quello che ho vissuto al sud mi ha portato a pensarlo, così come sono in parte veneto e quel che ho visto al nord mi aveva altrettanto portato ad avere questo erroneo pensiero.

Sono stati utilizzati il dataset “TFR20255_52000700” (codice del dataset utilizzato, reperibile al link:

[\(IT1,52_1194_DF_DCCV_POPTIT1_UNT2020_2,1.0\)” \(reperibile al link:](https://infostat.bancaditalia.it/inquiry/home?spyglass/taxo:CUBESET=/PUBBL_00/PUBBL_00_07/PUBBL_00_07_02/TFR20255&ITEMSELEZ=TFR20255_52000700:false&OPEN=false/&ep:LC=IT&COMM=BANKITALIA&ENV=LIVE&CTX=DIFF&IDX=2&/view:CUBEIDS=) ed il dataset “Popolazione per titolo di studio e regioni</p></div><div data-bbox=)

[https://esploradati.istat.it/databrowser/#/it/dw/categories/IT1.Z0820EDU.1.0/DCCV_POPTIT1_UNT2020/IT1,52_1194_DF_DCCV_POPTIT1_UNT2020_2,1.0\).](https://esploradati.istat.it/databrowser/#/it/dw/categories/IT1.Z0820EDU.1.0/DCCV_POPTIT1_UNT2020/IT1,52_1194_DF_DCCV_POPTIT1_UNT2020_2,1.0).)

In fondo al file è commentato l’output del modello di regressione lineare semplice applicato al dataset creato come “mix” di questi due dataset da cui sono stati raccolti i dati; in seguito ad un istogramma che mette in evidenza l’enorme disparità interregionale nell’ammontare di questa quantità.

CODICE R

```
# LIBRERIE
```

```
library(tidyverse)
```

```
library(readxl)
```

```
# PULIZIA DEL FILE "PRESTITI"
```

#caricamento dati sui prestiti:

```
dati_prestiti_raw <- read_excel("dati_prestiti.xlsx", skip = 1, col_names = FALSE)
```

#assegnazione nomi corretti alle colonne:

```
colnames(dati_prestiti_raw) <- c("id", "regione", "data", "ente", "settore", "attivita",  
"fenomeno", "ammontare")
```

#pulizia e aggregazione dati sui prestiti:

```
totali_regione <- dati_prestiti_raw %>%  
  select(regione, ammontare) %>%  
  mutate(ammontare = as.numeric(ammontare)) %>%  
  filter(!regione %in% c("Italia", "Italia insulare", "Italia meridionale", "Italia nord-occidentale",  
"Italia nord-orientale", "Italia centrale")) %>%  
  group_by(regione) %>%  
  summarise(totale_ammontare = sum(ammontare, na.rm = TRUE)) %>%  
  mutate(regione = case_when(  
    str_detect(regione, "Valle d'Aosta") ~ "Valle d'Aosta/Vallée d'Aoste",  
    str_detect(regione, "Trentino") ~ "Trentino-Alto Adige",  
    str_detect(regione, "Emilia") ~ "Emilia-Romagna",  
    str_detect(regione, "Friuli") ~ "Friuli-Venezia Giulia",  
    TRUE ~ regione  
  ))
```

PULIZIA DEL FILE "ISTRUZIONE"

#caricamento dati sull'istruzione:

```
nome_file_istruzione <- "Popolazione per titolo di studio e regioni.xlsx"  
dati_istruzione_raw <- read_excel(nome_file_istruzione, col_names = FALSE)
```

#pulizia, selezione, aggregazione e "standardizzazione" dati sull'istruzione:

```
istruzione_pronta <- dati_istruzione_raw %>%  
  select(regione = 1, popolazione_totale = 8, laureati = 13) %>%  
  mutate(  
    popolazione_totale = as.numeric(popolazione_totale),  
    laureati = as.numeric(laureati)  
  ) %>%  
  filter(!is.na(popolazione_totale)) %>%  
  mutate(regione = case_when(  
    str_detect(regione, "Valle d'Aosta") ~ "Valle d'Aosta/Vallée d'Aoste",  
    str_detect(regione, "Trentino|Bolzano") ~ "Trentino-Alto Adige",  
    str_detect(regione, "Emilia") ~ "Emilia-Romagna",  
    str_detect(regione, "Friuli") ~ "Friuli-Venezia Giulia",  
    TRUE ~ regione  
  )) %>%  
  group_by(regione) %>%  
  summarise(  
    popolazione_totale = sum(popolazione_totale, na.rm = TRUE),
```

```
    laureati = sum(laureati, na.rm = TRUE)
  ) %>%
  mutate(perc_laureati = (laureati / popolazione_totale) * 100) %>%
  select(regione, perc_laureati)
```

UNIONE DEI DATASET

#unione dei dataset "sistemati":

```
dataset_analisi <- inner_join(totali_regione, istruzione_pronta, by = "regione")
```

#check delle 20 righe nel dataset finale, una per ogni regione:

```
print("Controllo: numero di righe del dataset finale (dovrebbero essere 20):")
print(nrow(dataset_analisi))
print("Anteprima del dataset finale:")
print(head(dataset_analisi))
```

GRAFICO E REGRESSIONE

#grafico con asse delle ordinate in milioni di euro:

```
ggplot(dataset_analisi, aes(x = reorder(regione, -totale_ammontare), y = totale_ammontare /
1000000)) +
  geom_bar(stat = "identity", fill = "#0072B2") +
  labs(
    title = "Prestiti Totali Erogati per Regione",
    x = "Regione",
    y = "Ammontare Totale (Milioni di €)" # Etichetta corretta
  ) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```


#regressione lineare semplice:

```
modello <- lm(totale_ammontare ~ perc_laureati, data = dataset_analisi)
```

#risultati del modello:

```
print("Risultati del Modello di Regressione Lineare Semplice:")
summary(modello)
```

GRAFICO A BARRE PER I PRESTITI PER REGIONE



Spero di non essermi sbagliato, anche se in realtà spero proprio di aver sbagliato, perchè una disparità del genere è, mi perdoni il termine, davvero “imbarazzante”.

Non oso immaginare quanta ulteriore disparità si potrebbe trovare nell'utilizzare dati sui prestiti anche per attività diverse da quelle non finanziarie e delle famiglie produttrici.

Spero davvero di essermi sbagliato nel sommare le quantità dei prestiti.

OUTPUT REGRESSIONE LINEARE COMMENTATO

Call:

```
lm(formula = totale_ammontare ~ perc_laureati, data = dataset_analisi)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.839e+09	-2.858e+09	-1.238e+09	1.334e+09	1.561e+10

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.859e+08	2.774e+09	0.175	0.863
perc_laureati	1.074e+06	9.199e+05	1.167	0.258

Residual standard error: 4.492e+09 on 18 degrees of freedom

Multiple R-squared: 0.07036, Adjusted R-squared: 0.01871

F-statistic: 1.362 on 1 and 18 DF, p-value: 0.2584

- perc_laureati: Questa è la riga che ci interessa. Dice che per ogni punto percentuale in più di laureati in una regione, l'ammontare dei prestiti tende ad aumentare di circa 1.074.000 euro → relazione positiva: più istruzione, più prestiti. Così suggerirebbero i dati ad un primo impatto, ma;
- $\Pr(>|t|)$: p-value = 0.258 > 0.05 ci dice che il risultato non è statisticamente significativo e quindi non possiamo affermare con certezza che questa relazione sia reale e non dovuta al caso. In altre parole, il grado di istruzione da solo non sembra essere un predittore forte e affidabile per spiegare la disparità nell'ammontare dei prestiti per società non finanziarie e famiglie produttrici.

Molto probabilmente, il PIL di una regione si rivelerebbe un fattore molto più significativo, così come il numero di residenti o il numero di attività non finanziarie ed imprese produttrici.